

Entornos de la Transformación Digital **Machine Learning**

Maestría en Liderazgo y Gestión Estratégica de la Transformación Digital


Ing. Luz Santamaría Granados, Ph.D

Santoto, 2026

Tipos de **Machine Learning**

- ✓ Comprender las categorías principales del ML.
- ✓ Diferenciar aprendizaje supervisado y no supervisado.
- ✓ Identificar aplicaciones generativas y por refuerzo.
- ✓ Analizar el valor estratégico para las organizaciones.

Machine Learning Trends to Watch in 2026



AGENTIC AI & DECISION-MAKING

Autonomous task execution.
Multi-step workflows.
Direct action, not just prediction.



GENAI AS INFRASTRUCTURE

Deeply integrated into core workflows.
Powering daily business operations.



SMALL, SPECIALIZED MODELS

Task-specific and efficient.
Domain knowledge.
Speed and practicality.



MACHINE LEARNING AT THE EDGE

Processing on-device.
Real-time intelligence.
Data privacy.



MLOPS & LLMOPS MATURITY

Production reliability.
Monitoring & scaling.
Operational excellence.



HUMAN-AI COLLABORATION

AI as a co-worker.
Augmented roles.
Synergistic workflows.






RESPONSIBLE & EXPLAINABLE AI

Transparency in decisions.
Bias mitigation.
Trust & regulation.

Artificial Intelligence In Digital Transformation Market Report 2026

Major Segments

Artificial Intelligence (AI) In
Digital Transformation Market
Report 2026




The Business
Research Company

www.thebusinessresearchcompany.com

Link: <https://machinelearningmastery.com/7-machine-learning-trends-to-watch-in-2026/>

Machine Learning (ML)

The Complete, Practical Guide
to Taking Machine Learning
to Production



Diversidad de Algoritmos

Así como existen diferentes especies de animales, existen múltiples algoritmos diseñados para tareas específicas.

No existe el "mejor" algoritmo universal. La excelencia reside en identificar correctamente el problema antes de elegir la herramienta.

| Tipos de ML



Supervisado

Predice una respuesta
basada en datos
históricos.



No Supervisado

Descubre patrones
ocultos sin etiquetas
previas.



Generativo


Crea nuevos
contenidos originales.




Por Refuerzo

Aprende mediante
recompensas y
castigos.

Tipos de ML



Algoritmos de ML



Supervised	No supervised	Reinforcement	Generative
Linear Regression, Logistic Regression, Ridge Regression, Lasso Regression, Elastic Net, Decision Tree, Random Forest, Extra Trees (Extremely Randomized Trees), Support Vector Machine (SVM), Support Vector Regression (SVR), k-Nearest Neighbors (k-NN), Naïve Bayes , Gaussian Naïve Bayes, Bernoulli Naïve Bayes, Multinomial Naïve Bayes, Gradient Boosting, AdaBoost, XGBoost, LightGBM, CatBoost, Artificial Neural Networks (ANN), Multi-Layer Perceptron (MLP), Convolutional Neural Networks (CNN), Recurrent Neural Networks (RNN), Long Short-Term Memory (LSTM), Gated Recurrent Unit (GRU), Transformer (for supervised tasks).	K-Means , K-Medoids, Hierarchical Clustering (Agglomerative Clustering), DBSCAN, HDBSCAN, OPTICS, Mean Shift, Gaussian Mixture Model (GMM), Spectral Clustering, Affinity Propagation, Principal Component Analysis (PCA), Kernel PCA, Independent Component Analysis (ICA), t-SNE, UMAP, Isomap, Locally Linear Embedding (LLE), Autoencoder, Variational Autoencoder (VAE), Self-Organizing Map (SOM), Apriori, FP-Growth, One-Class SVM, Isolation Forest, Local Outlier Factor (LOF).	Q-Learning , Deep Q-Network (DQN), Double DQN, Dueling DQN, SARSA, Monte Carlo Control, Temporal Difference (TD) Learning, Policy Gradient, REINFORCE, Actor-Critic, Advantage Actor-Critic (A2C), Asynchronous Advantage Actor-Critic (A3C), Proximal Policy Optimization (PPO), Trust Region Policy Optimization (TRPO), Deep Deterministic Policy Gradient (DDPG), Twin Delayed DDPG (TD3), Soft Actor-Critic (SAC), AlphaZero, MuZero.	Generative Adversarial Network (GAN) , Deep Convolutional GAN (DCGAN), Conditional GAN (CGAN), CycleGAN, StyleGAN, Variational Autoencoder (VAE), Vector Quantized VAE (VQ-VAE), Diffusion Models, Denoising Diffusion Probabilistic Models (DDPM), Latent Diffusion Models (LDM), Transformer, Generative Pre-trained Transformer (GPT), Bidirectional Encoder Representations from Transformers (BERT)*, T5 (Text-to-Text Transfer Transformer), BART, PixelCNN, PixelRNN, Normalizing Flows, Autoregressive Models, Restricted Boltzmann Machine (RBM), Deep Belief Network (DBN).

Aplicabilidad de ML

Categoría	Objetivo	Datos de entrenamiento	Algoritmos representativos	Casos de uso	Ventajas	Limitaciones
Aprendizaje Supervisado	Aprender una función que relacione entradas con salidas conocidas.	Datos etiquetados (entrada + respuesta correcta).	Regresión Lineal, Regresión Logística, Árboles de Decisión, Random Forest, SVM, k-NN, Redes Neuronales, XGBoost.	Clasificación de correos spam, predicción de ventas, diagnóstico médico, reconocimiento de imágenes.	Alta precisión cuando existen suficientes datos etiquetados. Fácil evaluar el rendimiento.	Requiere grandes volúmenes de datos etiquetados, cuyo etiquetado puede ser costoso.
Aprendizaje No Supervisado	Descubrir patrones, estructuras o relaciones ocultas en los datos.	Datos sin etiquetas	K-Means, DBSCAN, Clustering Jerárquico, PCA, t-SNE, Autoencoders, Reglas de Asociación (Apriori).	Segmentación de clientes, detección de anomalías, reducción de dimensionalidad, análisis exploratorio.	No necesita datos etiquetados. Útil para descubrir conocimiento desconocido.	Difícil evaluar los resultados. La interpretación puede ser subjetiva.
Modelos Generativos	Aprender la distribución de los datos para generar nuevos ejemplos similares.	Datos etiquetados o no etiquetados, según el modelo.	GANs, VAEs, Transformers Generativos (GPT), Modelos de Difusión, Modelos Autorregresivos.	Generación de texto, imágenes, audio, código, síntesis de datos, diseño de moléculas.	Capacidad de crear contenido nuevo y aumentar conjuntos de datos.	Alto costo computacional. Requieren grandes cantidades de datos y entrenamiento.
Aprendizaje por Refuerzo	Aprender una estrategia óptima mediante prueba y error para maximizar una recompensa.	Interacción con un entorno mediante estados, acciones y recompensas.	Q-Learning, SARSA, Deep Q Networks (DQN), PPO, A3C, Actor-Critic, SAC.	Robótica, videojuegos, vehículos autónomos, optimización de procesos, gestión de recursos.	Aprende estrategias complejas sin ejemplos explícitos y se adapta al entorno.	Entrenamiento lento, requiere muchas interacciones y un diseño adecuado de la función de recompensa.

| Aprendizaje Supervisado

Datos Etiquetados

Disponemos de datos históricos donde conocemos la "respuesta correcta". El modelo aprende el mapeo entre entradas y salidas.


Fórmula del Aprendizaje

Variables de entrada (X)



Variable Objetivo (Y)

Aplicación de ML



CLASIFICACIÓN VS REGRESIÓN

Clasificación

Predice **categorías** o clases discretas.

Ejemplo:

¿Es fraude o no?


¿Compra o no compra?

Regresión

Predice **valores numéricos** continuos.

Ejemplo:

¿Cuál será el precio de la vivienda?



Aprendizaje Supervisado




Utiliza ejemplos históricos en los que ya conocemos la respuesta correcta (la variable objetivo) para aprender una función que permita realizar predicciones sobre nuevos datos.



Clasificación: el resultado pertenece a una categoría: ¿un cliente abandonará el servicio: sí/no?



Regresión: el resultado es un valor numérico: ¿cuál será la venta del próximo mes?



Entrenamiento: el algoritmo identifica patrones entre las características de entrada y la variable objetivo.



Evaluación: se mide qué tan bien generaliza el modelo con datos que no utilizó para aprender.



Predicción: el modelo entrenado transforma nuevos datos en una estimación que puede apoyar decisiones organizacionales.

ALGORITMOS DE REGRESIÓN


Familia	Algoritmos Comunes
Lineales	Regresión Lineal, Ridge, Lasso, Elastic Net
No Lineales	Árboles de Decisión, Random Forest Regressor
Avanzados	Gradient Boosting, Redes Neuronales (MLP)




ALGORITMOS DE CLASIFICACIÓN

- **Regresión Logística:** Ideal para problemas binarios.
- 🌳 **Árboles de Decisión:** Altamente interpretables.
- 🌲 **Random Forest:** Conjunto de árboles para mayor robustez.
- ⚡ **Gradient Boosting:** Alta precisión competitiva.
- 🧠 **Redes Neuronales:** Para patrones de alta complejidad.


Classifiers on feature subsets of the Iris dataset



Aprendizaje semisupervisado



 Datos disponibles



APRENDIZAJE NO SUPERVISADO

Sin Objetivo (Y)

Solo contamos con información (X).
El algoritmo intenta encontrar la estructura intrínseca de los datos sin guía externa.

Misión: Explorar

No busca predecir el futuro, sino **entender el presente** oculto en grandes volúmenes de datos brutos.


CLUSTERING (AGRUPAMIENTO)


Segmentación Inteligente

Agrupar observaciones similares automáticamente. Es fundamental para la **personalización masiva**.


Uso: Segmentación de clientes, agrupación de productos, detección de comunidades.

Algoritmos: K-Means, Clustering Jerárquico.





REDUCCIÓN DE DIMENSIONALIDAD



Simplificar lo Complejo

Busca reducir el número de variables (ruido) manteniendo la información esencial.

Beneficios: Visualización mejorada, aceleración de modelos y eliminación de redundancias.

Método: **PCA** (Principal Component Analysis).

APRENDIZAJE GENERATIVO

El objetivo es **crear contenido nuevo** inspirado en datos originales.

No copia; aprende la distribución estadística para producir texto, imágenes o código totalmente nuevos.



APRENDIZAJE GENERATIVO

Este es un ejemplo para aprender a generar datos sintéticos para investigación o aplicaciones reales usando una (Generative Adversarial Network, GAN) :

- El Generador (G) intenta engañar al discriminador produciendo datos sintéticos.
- El Discriminador (D) intenta distinguir entre datos reales y generados.
- Ambos se entrenan simultáneamente, mejorando uno en respuesta al otro.
- Este ciclo se repite durante miles de épocas (epochs).

Preparación de datos

- Generar datos
- Normalizar

Construcción de la GAN

- Generador
- Discriminador

Entrenamiento

- Generar datos falsos
- Entrenar Discriminador
- Entrenar Generador

Generación de datos



- Crear nuevos datos sintéticos

Visualización

- Comparar datos
- Mostrar pérdidas

APRENDIZAJE GENERATIVO

GAN aprendiendo una distribución bidimensional



APLICACIONES DE GENERATIVE AI (GenAI)

600 × 400

Marketing & Copys

600 × 400


Generación de Código

600 × 400

Simulación & Datos

Ejemplos: Grok, Kimi, DeepSeek, ChatGPT, DALL·E,
Midjourney, Gemini.

APRENDIZAJE POR REFUERZO




Ensayo y Error

El modelo (agente) toma decisiones en un entorno para maximizar una **recompensa acumulada**.

Ciclo de Aprendizaje

Maximizar la recompensa acumulada

APRENDIZAJE POR REFUERZO



- **Agente:** sistema que toma decisiones, por ejemplo, un robot, un sistema de recomendación o un sistema empresarial.
- **Entorno:** contexto en el que opera el agente y sobre el cual sus acciones tienen consecuencias.
- **Estado (S_t):** información disponible del entorno en un momento determinado.
- **Acción (A_t):** decisión que toma el agente.
- **Recompensa (R_t):** señal que indica qué tan favorable fue la consecuencia de la acción.
- **Política:** estrategia que relaciona los estados observados con las acciones que conviene explorar o ejecutar.
- **Aprendizaje:** el agente modifica su política a partir de la experiencia, buscando **maximizar la recompensa acumulada**, no necesariamente obtener la mayor recompensa inmediata.

FRONTERAS DEL REFUERZO



Automatización Extrema

Ideal para sistemas dinámicos que requieren decisiones secuenciales.

-  Vehículos autónomos.
-  Robótica industrial.
-  Trading algorítmico.
-  Optimización logística.

ENTRENAMIENTO BATCH (OFFLINE)

Aprendizaje por Lotes

Estático

- Se recopilan datos históricos, se entrena el modelo y se despliega como una pieza fija.
- Requiere un nuevo entrenamiento completo para actualizarse.
- Es el **estándar organizacional** actual por su estabilidad.

ENTRENAMIENTO ONLINE



Adaptación en Tiempo Real

- El modelo aprende continuamente de cada nuevo dato que recibe.
- Es ideal para entornos que cambian rápidamente como la publicidad digital o sistemas de recomendación.

| ¿CUÁL ELEGIR?

Característica	Batch Learning	Online Learning
Actualización	Periódica (Lotes)	Continua (Flujo)
Complejidad	Baja / Media	Alta
Adaptabilidad	Lenta (Estático)	Instantánea (Dinámico)
Caso de Uso	Riesgo Crediticio	Sistemas de Navegación

CREACIÓN VS DESTRUCCIÓN DE VALOR

Genera Valor

Reduce costos, aumenta ingresos y mejora decisiones estratégicas con datos de alta fidelidad.

Destruye Valor

Resuelve el problema equivocado con datos deficientes, aumentando la desconfianza organizacional.

PERSPECTIVA DEL LIDERAZGO

“

II *La pregunta directiva no es ¿qué algoritmo usar?,
sino ¿qué problema estratégico queremos resolver y
cómo mediremos el valor creado?*

COMPETENCIAS DEL LÍDER



Visión

Identificar oportunidades de negocio reales.



Gestión

Liderar equipos multidisciplinarios.



Ética

Gestionar riesgos y cumplimiento.



| RESUMEN DE LA SESIÓN

Supervisado

Predicción conocida.

No Supervisado

Patrones ocultos.

Generativo

Creación de contenido.

Refuerzo

Aprendizaje por premios.

Batch

Entrenamiento estático.

Online

Entrenamiento vivo.

| Recomendación

- ★ El algoritmo debe adaptarse al **problema de negocio**, no al revés.
- ★ No todos los proyectos requieren IA avanzada, a veces la **simplicidad** es el éxito.
- ★ El éxito se mide por el **valor estratégico**, no solo por la precisión técnica.
- ★ El **ML** consiste en encontrar el algoritmo adecuado y resolver el problema correcto para **generar valor sostenible**.

PREGUNTAS PARA DISCUSIÓN

¿Supervisado?

¿Qué procesos de su organización se beneficiarían de predicciones basadas en datos históricos?

¿Valor?

¿Cómo mediría usted hoy el retorno de inversión (ROI) de un proyecto de ML en su área?

| bibliografía

- Olumide, Shittu (2026). Machine Learning Trends to Watch in 2026. Practical Machine Learning. <https://machinelearningmastery.com/7-machine-learning-trends-to-watch-in-2026/>.
- Geertsema, Paul (2023). Machine Learning for Managers. First published by Routledge. Taylor & Francis Group, an informa business.
- Hwang, Y. y Burtch, N. (2024). *Machine Learning and Generative AI for Marketing*. Packt Publishing. ISBN 978-1-83588-940-4.
- Ping, D. (2024). The Machine Learning Solutions Architect Handbook. Packt Publishing. ISBN 978-1-80512-250-0.
- Reddi, J. (2025). Machine Learning Systems. School of Engineering and Applied Sciences Harvard University.
- Fuentes, A. (2018). Become a Python Data Analyst. Packt Publishing. ISBN 978-1-78728-430-2.