
MAESTRÍA EN LIDERAZGO Y GESTIÓN ESTRATÉGICA DE LA TRANSFORMACIÓN DIGITAL

Algoritmos de Machine Learning - De los Datos Operacionales a la Creación de Valor Sostenible

Maestría en Liderazgo y Gestión Estratégica de la Transformación Digital

Ing. Luz Santamaría Granados, Ph.D

Santoto, 2026

Machine Learning en la Transformación Digital

1. De la Digitalización a la Inteligencia

- La transformación digital no culmina en la nube ni en flujos automatizados.
- Su valor real emerge al habilitar **capacidades predictivas sistemáticas** que anticipan demandas, mitigan riesgos operacionales y personalizan servicios.

2. El Dato como Activo Estratégico

- Los datos transaccionales, telemétricos y de los clientes deben integrarse en **arquitecturas analíticas** con algoritmos capaces de **reducir la incertidumbre** en la toma de decisiones.

3. El Rol del Líder y Gestor Digital

- Cerrar la brecha entre la analítica de datos y la junta directiva.
- **Garantizar la gobernanza**, el retorno de inversión (ROI), la mitigación de sesgos y modelos auditables y éticos.

Taxonomía General del Machine Learning: Dos Paradigmas estratégicos

1. Aprendizaje Supervisado ($X \rightarrow y$)

Modelo predictivo guiado por datos históricos con una variable objetivo conocida:


- **Clasificación (Target Discreto):** Identificación de estados categóricos como detección de fraude, abandono de clientes (churn) o diagnósticos críticos.
- **Regresión (Target Continuo):** Estimación de magnitudes numéricas como modelos de pricing, tasación de activos inmobiliarios o proyección de demanda.
- **Métrica de éxito:** Reducción del error de generalización sobre datos de prueba no observados (**Holdout test set**).

2. Aprendizaje No Supervisado (X)

Descubrimiento de estructuras y relaciones ocultas sin etiquetas previas:


- **Agrupamiento (Clustering):** Segmentación natural de clientes o carteras según hábitos de consumo, ingresos y afinidades operacionales.
- **Reducción Dimensional (PCA):** Síntesis de múltiples indicadores correlacionados en macroejes ortogonales conservando la máxima varianza.
- **Métrica de Éxito:** Cohesión intra-cluster y separación inter-cluster evaluada mediante el Coeficiente de Silueta (**Silhouette Coefficient**).

Tipos de ML





Modelos de machine Learning Supervisados



Modelos Supervisados: Lineales, Proximidad y Márgenes Óptimos

Regresión Logística

- Fundamento: Modela probabilidades de pertenencia mediante la **función sigmoide**.
- Ventaja Directiva: Máxima explicabilidad mediante Odds Ratios. Es el **estándar regulatorio en banca y seguros**.
- Limitación: Asume fronteras de decisión lineales entre clases.

K-Nearest Neighbors (KNN)

- Fundamento: Clasifica un nuevo evento por la clase mayoritaria de sus k vecinos más cercanos en el espacio euclidiano.
- Ventaja Directiva: Razonamiento intuitivo basado en casos históricos previos.
- Limitación: Alto costo en inferencia $O(N)$. Requiere estandarización rigurosa.

Support Vector Machines (SVM)

- Fundamento: Maximiza el margen geométrico entre clases extremas (vectores de soporte).
- Ventaja Directiva: Altísima precisión en espacios multidimensionales con fronteras no lineales mediante Kernel RBF.
- Limitación: Mayor costo de cómputo en grandes volúmenes.

Modelos Supervisados: Logistic Regression

La regresión logística se utiliza principalmente para clasificación binaria.

- ¿Un cliente abandonará o permanecerá?
- ¿Una transacción es fraudulenta o legítima?
- ¿Un usuario adoptará o no adoptará una nueva tecnología?
- ¿Un proyecto tiene riesgo alto o bajo?

Primero calcula una combinación lineal de las variables:

$$z = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_n x_n$$


Luego transforma ese resultado mediante la función sigmoide:

$$P(Y = 1 | X) = \frac{1}{1 + e^{-z}}$$

Resultado: una probabilidad entre 0 y 1.

Ejemplo:

$P(\text{churn} = 1) = 0.82 \rightarrow$ el modelo estima un 82 % de probabilidad de abandono.




Modelos Supervisados: Logistic Regression

La probabilidad no es todavía la clasificación, el modelo necesita un umbral de decisión:

$$\hat{Y} = \begin{cases} 1 & \text{si } P(Y = 1|X) \geq 0.5 \\ 0 & \text{si } P(Y = 1|X) < 0.5 \end{cases}$$

Cliente	Probabilidad de abandono	Umbral	Predicción
A	0.18	0.50	● Permanece
B	0.47	0.50	● Permanece
C	0.73	0.50	● Abandona
D	0.91	0.50	● Abandona



Modelos Supervisados: K-Nearest Neighbors

KNN (K vecinos más cercanos) es un algoritmo de Machine Learning que realiza una predicción observando los K casos más similares a un nuevo caso.

1. Tenemos datos históricos → Clientes que abandonaron / permanecieron
2. Llega un nuevo cliente → Queremos predecir si abandonará.
3. Calculamos la distancia → ¿Qué clientes históricos son más similares?
4. Seleccionamos los K vecinos más cercanos
5. Votación mayoritaria → La clase con más vecinos determina la predicción.

Neighbors	behavior
 Customer A	no churn
 Customer B	no churn
 Customer C	churn
 Customer D	churn
 Customer E	churn

Resultado:



3 abandonaron



2 permanecieron



Predicción KNN: Abandona

KNN no aprende una función explícita; utiliza la proximidad entre observaciones para realizar la predicción.


Modelos Supervisados: K-Nearest Neighbors

Distancia euclidiana: Para dos observaciones:

$$d(A, B) = \sqrt{(x_1^A - x_1^B)^2 + (x_2^A - x_2^B)^2}$$

Cuanto menor sea la distancia → mayor similitud:

K	Comportamiento
K = 1	Decide por el vecino más cercano
K = 3	Votación entre 3 vecinos
K = 5	Votación entre 5 vecinos
K grande	Considera más información, pero puede perder particularidades locales



Modelos Supervisados: K-Nearest Neighbors

- KNN convierte la similitud entre clientes, transacciones, usuarios o eventos en una decisión predictiva.
- Puede utilizarse, por ejemplo, para **segmentación**, **detección de comportamientos similares**, **recomendación** y **clasificación** de clientes.

¿Qué podría ocurrir si una variable está medida en miles y otra entre 0 y 1?

Esto permite introducir el concepto de **normalización/estandarización de variables**, que es fundamental para los algoritmos de ML.

	Age	Annual Income	Spending Score
count	15079.00	15079.00	15079.00
mean	54.19	109742.88	50.59
std	21.12	52249.43	28.73
min	18.00	20022.00	1.00
25%	36.00	64141.00	26.00
50%	54.00	109190.00	51.00
75%	72.00	155008.00	75.00
max	90.00	199974.00	100.00

Modelos Supervisados: StandardScaler

- En el caso del dataset de segmentación de clientes, si no se estandarizan las variables, el ingreso anual monopolizaría el 99% de la distancia euclidiana, anulando el impacto del hábito de gasto y la edad.
- Aplicamos **StandardScaler** (media =0, desviación estándar=1) para garantizar una ponderación equitativa en la arquitectura analítica.

$$z = \frac{x - \mu}{\sigma}$$

```
from sklearn.preprocessing import StandardScaler

# Exclusión del identificador único (CustomerID no aporta valor predictivo)
variables_segmentacion = ['Age', 'Annual Income', 'Spending Score']
X = df[variables_segmentacion]

# Estandarización formal
scaler = StandardScaler()
X_scaled = scaler.fit_transform(X)

df_escalado = pd.DataFrame(X_scaled, columns=['Age_Std', 'Income_Std', 'Spending_Std'])
print("Variables estandarizadas con éxito para modelado no supervisado:")
display(df_escalado.head())
```

	Age_Std	Income_Std	Spending_Std
0	-1.145516	0.798813	1.337059
1	0.180335	1.442076	1.545929
2	0.369742	-0.743208	0.884507
3	-1.476979	-1.038953	0.223086
4	-1.429627	0.842317	0.884507


Modelos Supervisados: Support Vector Machine (SVM)

- SVM permite encontrar un límite o frontera de decisión que separe las clases dejando el mayor margen posible entre ellas.

Para los dos grupos de clientes (churn, no churn), existen muchas fronteras que podrían separarlos.

SVM busca aquella que:

1. **Separa las clases** → Diferencia los grupos.
2. **Maximiza el margen** → Mantiene la mayor distancia posible respecto a los casos de cada clase.
3. **Identifica los Support Vectors** → Son las observaciones más cercanas a la frontera y las que determinan su posición.
4. Si los datos NO pueden separarse con una línea? Se usa un **Kernel (Linear, Polynomial o Radial Basis Function, RBF)** que transforma el espacio de representación.




Modelos Supervisados: Support Vector Machine (SVM)

- Si tuviéramos que clasificar clientes como “alto riesgo” o “bajo riesgo”, ¿qué características podrían convertirse en Support Vectors?

Los **Support Vectors** serían aquellos clientes cuyos datos están **más cerca de la frontera** entre “alto riesgo” y “bajo riesgo”.

Por ejemplo, podríamos utilizar:

- Número de transacciones realizadas
- Frecuencia de uso de la plataforma
- Antigüedad del cliente
- Número de reclamos
- Valor promedio de las compras
- Tiempo desde la última interacción



Modelos Supervisados: Árboles y Ensambles

Árboles de Decisión (CART)

- Mecanismo: Reglas jerárquicas si-entonces basadas en ganancia de información (**Gini**).
- Ventaja: Comprensión directa por comités y equipos no técnicos.
- Riesgo: Propenso a sobreajuste si no se limita max_depth.

Random Forest (Bagging)

- Mecanismo: Ensamble de cientos de árboles independientes en paralelo.
- Ventaja: Gran resistencia al ruido; ranking de importancia de variables.
- Balance: **Mayor memoria**; menor lectura directa que un árbol único.

Gradient Boosting / XGBoost


- Mecanismo: Árboles secuenciales optimizados por descenso de gradiente.
- Ventaja: Estado del arte en precisión para datos tabulares y transaccionales.
- Balance: Demanda **afinamiento** riguroso de **hiperparámetros**.

Modelos Supervisados: Decision Tree (Árbol de Decisión)

- Es un algoritmo de Machine Learning supervisado que aprende una secuencia de reglas para realizar clasificaciones o predicciones.

Estructura Jerárquica del Árbol de Decisión (Breast Cancer Wisconsin - Profundidad Máx: 4)

Elemento	Significado
Nodo raíz	Primera pregunta o variable utilizada
Nodo de decisión	Pregunta que divide los datos
Rama	Resultado de una decisión
Hoja	Predicción final
Profundidad	Cantidad de niveles del árbol



Modelos Supervisados: Decision Tree (Árbol de Decisión)

- El árbol busca las preguntas que mejor separan los datos.
- No todas las preguntas producen una división igualmente útil.
- El algoritmo evalúa diferentes variables y puntos de corte para encontrar una división que genere grupos más homogéneos.

1. **Índice Gini:** mide qué tan mezcladas están las clases en un nodo. $Gini = 0 \rightarrow$ nodo completamente puro.

$$Gini = 1 - \sum_{k=1}^K p_k^2$$

2. **Entropía:** Mide el nivel de incertidumbre. Entropía = 0 $\rightarrow$ nodo completamente puro.

$$H = - \sum_{k=1}^K p_k \log_2(p_k)$$

Modelos Supervisados: Decision Tree (Árbol de Decisión)

- **Overfitting**: Un árbol demasiado profundo puede memorizar los datos de entrenamiento y tener un peor desempeño con nuevos datos.

Un modelo **Decision Tree** transforma datos en reglas de decisión que pueden ser interpretadas por las personas, pero necesita controlar su complejidad para **generalizar** correctamente ante nuevos casos. Con capacidad **predictiva** e **interpretativa**.

Por eso utilizamos técnicas como:

max_depth → limita la profundidad.

min_samples_split → exige un mínimo de observaciones para dividir un nodo.

min_samples_leaf → establece un mínimo de observaciones en las hojas.


Poda (*pruning*) → elimina ramas que aportan poco a la capacidad de generalización.

Modelos Supervisados: Random Forest

- RF es un algoritmo de Machine Learning que combina múltiples árboles de decisión para obtener una predicción más robusta.

Bagging = Bootstrap Aggregating

1. Se generan diferentes muestras de entrenamiento mediante **bootstrap**.
2. Se construye un árbol con cada muestra.
3. Cada árbol realiza su propia predicción.
4. Se combinan todas las predicciones.



Modelos Supervisados: Random Forest

- RF es un algoritmo de Machine Learning que combina múltiples arboles de decisión para obtener una predicción más robusta.


Tree	Prediction
 1	churn
 2	no churn
 3	churn
 4	churn
 5	churn

Votación:

Abandona → 4 votos

Permanece → 1 voto

➡ Predicción final: Abandona



Modelos Supervisados: Random Forest vs Decision Tree

- Un Random Forest introduce aleatoriedad en dos niveles: Bootstrap de observaciones, es decir, cada árbol recibe una muestra diferente de los datos (mayor robustez).


Selección aleatoria de variables

1. Reduce el **sobreajuste** respecto a un árbol individual en muchos escenarios.
2. Es robusto frente a variaciones de los datos.
3. Puede manejar numerosas variables.
4. Permite estimar la **importancia de las características**.

Combinar múltiples modelos relativamente débiles o variables perspectivas diferentes puede producir un sistema predictivo más robusto. Sin embargo, no es únicamente la cantidad de árboles, sino la **diversidad entre ellos** y su **capacidad de generalización**.

Modelos Supervisados: XGBoost (Extreme Gradient Boosting)

- XGBoost es una implementación optimizada de Gradient Boosting basada en árboles de decisión. Construye modelos potentes, eficientes y regularizados, controlando el riesgo de overfitting.
- Cada nuevo árbol se incorpora para mejorar la predicción del modelo acumulado.



Parámetro	¿Qué controla?
n_estimators	Número de árboles
learning_rate	Cuánto aporta cada árbol
max_depth	Profundidad de los árboles
subsample	Proporción de observaciones utilizadas
colsample_bytree	Proporción de variables utilizadas
reg_alpha / reg_lambda	Regularización

Modelos Supervisados: XGBoost (Extreme Gradient Boosting)

- Un **learning_rate** pequeño significa que cada árbol realiza una corrección más pequeña.
- **Gradient Boosting** aprende secuencialmente de los errores y **XGBoost** lleva esta estrategia a una implementación altamente optimizada, incorporando regularización y múltiples mecanismos para controlar el sobreajuste.

Concepto	Pregunta que responde
n_estimators	¿Cuántos árboles construimos?
learning_rate	¿Cuánto aporta cada árbol?
max_depth	¿Qué tan complejo puede ser cada árbol?
Overfitting	¿Estamos aprendiendo demasiado los datos de entrenamiento?
Early stopping	¿Cuándo debemos dejar de agregar árboles?

Learning Rate + Número de árboles + Complejidad → Generalización

```
from xgboost import XGBClassifier
modelo_xgboost = XGBClassifier(n_estimators=100, max_depth=3, learning_rate=0.1, random_state=42, eval_metric='logloss')
nombre_xgb = "XGBoost (Extreme Gradient Boosting)"
```


Modelos Supervisados: Redes Neuronales

Una neurona combina entradas, pesos y un sesgo

$$z = w_1x_1 + w_2x_2 + \dots + w_nx_n + b$$


$$a = g(z)$$

- **Pesos w :** indican la importancia y dirección de cada entrada.
- **Sesgo b :** permite desplazar el umbral de activación.
- **Función g :** introduce no linealidad y permite aprender relaciones complejas.



Modelos Supervisados: Arquitectura de una Red Neuronal MLP

Multi-Layer Perceptron: varias capas densamente conectadas




- **Capa de entrada:** recibe las características del problema.
- **Capas ocultas:** transforman progresivamente la representación de los datos.
- **Capa de salida:** produce la predicción final.
- **Densamente conectada:** significa que cada neurona de una capa se conecta con todas las de la siguiente.

$$a^{(l)} = g^{(l)}(W^{(l)} a^{(l-1)} + b^{(l)})$$

Modelos Supervisados: Redes Neuronales Artificiales

Las funciones de activación permiten que la red aprenda relaciones no lineales



Sigmoide

$$\sigma(z) = 1 / (1 + e^{-z})$$

Útil en salidas binarias; rango (0, 1).

tanh

$$\tanh(z) = (e^z - e^{-z}) / (e^z + e^{-z})$$

Rango (-1, 1).

ReLU

$$\text{ReLU}(z) = \max(0, z)$$

Frecuente en capas ocultas.

Modelos Supervisados: Redes Neuronales

Propagación hacia adelante (forward propagation): La información fluye desde las entradas hasta la predicción.

$$\mathbf{z}^{(1)} = \mathbf{W}^{(1)}\mathbf{x} + \mathbf{b}^{(1)}$$

$$\mathbf{a}^{(1)} = g^{(1)}(\mathbf{z}^{(1)})$$

$$\mathbf{z}^{(2)} = \mathbf{W}^{(2)}\mathbf{a}^{(1)} + \mathbf{b}^{(2)}$$

$$\hat{\mathbf{y}} = g^{(2)}(\mathbf{z}^{(2)})$$

- Cada capa recibe la activación de la capa anterior.
- Los pesos y sesgos determinan la transformación.
- La salida $\hat{\mathbf{y}}$ es la predicción que se compara con la etiqueta real.
- En inferencia, solo se realiza este recorrido; no se actualizan los parámetros.

$\mathbf{X} \rightarrow \text{Capa 1} \rightarrow \text{Capa 2} \rightarrow \dots \rightarrow \hat{\mathbf{y}}$

Modelos Supervisados: Redes Neuronales

Función de pérdida: Cuantifican qué tan lejos está la predicción de la respuesta esperada

Regresión: error cuadrático medio (MSE)

Penaliza el cuadrado de la diferencia entre el valor real y el predicho.

$$\text{MSE} = (1/m) \sum_i (y_i - \hat{y}_i)^2$$

Clasificación binaria: entropía cruzada


Evalúa la probabilidad asignada a la clase correcta.

$$J = -(1/m) \sum_i [y_i \log \hat{y}_i + (1-y_i) \log(1-\hat{y}_i)]$$

Objetivo del entrenamiento: minimizar J mediante el ajuste de W y b.

Modelos Supervisados: Redes Neuronales

Los parámetros se ajustan a partir de ejemplos; no se programan reglas explícitas



- Una época (**epoch**) es un recorrido completo por el conjunto de entrenamiento (**training**).
- La pérdida (**loss**) suele disminuir al encontrar parámetros más adecuados.
- La disminución de la pérdida de entrenamiento no garantiza generalización.
- Se debe evaluar (**testing**) con datos no utilizados durante el ajuste.

Sobreajuste (**overfitting**): el modelo memoriza patrones del entrenamiento y falla con datos nuevos.

Modelos Supervisados: Redes Neuronales Artificiales

Perceptrón Multicapa (Multi-Layer Perceptron)

MLP:

Arquitectura inspirada en redes biológicas: capa de entrada, capas ocultas con transformaciones no lineales (ej. ReLU) y capa de salida probabilística.


Mecanismo de Aprendizaje:

Calibración iterativa de pesos sinápticos mediante propagación hacia adelante y retropropagación del error (*Backpropagation*) optimizado por gradiente.

Perspectiva Gerencial:

Fortaleza: Capacidad de aproximación universal ante interacciones complejas.

Trade-off: Naturaleza de "caja negra"; requiere mayor volumen de datos, estricto preprocesamiento de escala y marcos de explicabilidad (XAI).



Modelos Supervisados: Redes Neuronales Artificiales

Ejemplo: predicción de abandono (**churn**) de usuarios de una plataforma digital.

Datos de entrada

- frecuencia de uso
- número de sesiones
- tiempo desde el último acceso
- tickets de soporte
- uso de funcionalidades
- tipo de plan

Modelo MLP

- **Capa de entrada → capas ocultas → salida sigmoide.**
- La red aprende combinaciones de comportamiento que se relacionan con el abandono (churn).

Resultado

Probabilidad estimada:

$$P(\text{churn} = 1 \mid X)$$

La organización puede priorizar acciones de retención, validación y criterios éticos.

$$\hat{y} = \sigma(W^{(L)} a^{(L-1)} + b^{(L)})$$



Métricas de evaluación de modelos de machine Learning

Métricas de desempeño

- Son medidas cuantitativas utilizadas para determinar: qué tan bien se desempeña un modelo de ML al realizar predicciones sobre datos que no ha visto durante su entrenamiento.
- La elección de la métrica depende del tipo de problema, las características de los datos y las consecuencias de los errores de predicción en el contexto empresarial u operativo.
- Un modelo no debe considerarse bueno simplemente porque obtiene un valor alto en una métrica.
- La métrica seleccionada debe estar alineada con el objetivo del problema y con el impacto de las decisiones que se tomarán a partir de las predicciones.



Confusion Matrix

La Matrix de Confusión es una herramienta fundamental para evaluar modelos de clasificación y permite comparar la clase real de cada observación con la clase predicha por el modelo.

	Predicted Positive	Predicted Negative
Actual Positive	True Positive (TP)	False Negative (FN)
Actual Negative	False Positive (FP)	True Negative (TN)

- **True Positive (TP):** el modelo predice una clase positiva y el valor real también es positivo.
- **True Negative (TN):** el modelo predice una clase negativa y el valor real también es negativo.
- **False Positive (FP / Error Tipo I):** el modelo predice una clase positiva, pero el valor real es negativo.
- **False Negative (FN /Error Tipo II):** el modelo predice una clase negativa, pero el valor real es positivo.

Los modelos no se evalúan por exactitud ciega, sino por la minimización del costo asimétrico del error según la estrategia de negocio.

Matriz de Confusión — Regresión Logística
(Dataset Breast Cancer: 114 Casos de Prueba)

Etiqueta Real (Diagnóstico)	Etiqueta Predicha por el Modelo	
	Predicho: Maligno (0)	Predicho: Benigno (1)
Real: Maligno (0)	Verdadero Maligno (TP) 41 (36.0%)	Falso Benigno (FN) 1 (0.9%)
Real: Benigno (1)	Falso Maligno (FP) 1 (0.9%)	Verdadero Benigno (TN) 71 (62.3%)

Métricas de Evaluación – Desempeño en Clasificación


MÉTRICA	FÓRMULA MATEMÁTICA	¿QUÉ MIDE?	RELEVANCIA EN EL PROBLEMA
EXACTITUD (Accuracy)	$(TP + TN) / (TP + TN + FP + FN)$	Porcentaje total de predicciones correctas (tanto positivas como negativas) sobre el total de casos.	Visión general del desempeño. Es útil cuando las clases están razonablemente balanceadas.
PRECISIÓN (Precision)	$TP / (TP + FP)$	De todos los casos que el modelo clasificó como positivos , ¿cuántos lo eran en realidad?	Mide la calidad o confiabilidad de las alertas positivas. Penaliza los falsos positivos.
EXHAUSTIVIDAD (Recall / SENSIBILIDAD)	$TP / (TP + FN)$	De todos los casos que realmente eran positivos , ¿cuántos logró detectar el modelo?	Mide la cobertura . En diagnóstico médico es la métrica más crítica: un <i>Falso Negativo</i> significa no detectar una patología a tiempo.
F1-Score	$2 \times (Precision \times Recall) / (Precision + Recall)$	Media armónica balanceada entre la Precisión y el Recall.	Ofrece una evaluación integral, penalizando fuertemente a los modelos que descuidan una métrica en favor de la otra.

Desempeño Comparativo de Modelos de Clasificación

Métricas en Conjunto de Prueba (Test Set)

Modelo	Acc	Prec	Rec	F1
Regresión Logística	98.25%	98.61%	98.61%	98.61%
SVM (Kernel RBF)	98.25%	98.61%	98.61%	98.61%
Gradient Boosting	97.37%	96.00%	100.00%	97.96%
Red Neuronal (MLP)	96.49%	98.57%	95.83%	97.18%
Random Forest	95.61%	95.89%	97.22%	96.55%
KNN (k=5)	95.61%	95.89%	97.22%	96.55%
Decision Tree	93.86%	95.77%	94.44%	95.10%

Comparativa Gráfica de Puntuaciones



Métricas de Evaluación – Curva ROC y AUC

La Curva **ROC** (**Receiver Operating Characteristic**) permite evaluar el desempeño de un clasificador binario utilizando diferentes umbrales de decisión.

El **AUC** (**Area Under the Curve**) representa la capacidad del modelo para distinguir entre las diferentes clases a través de distintos umbrales de decisión. Resume la Curva ROC en un único valor entre 0 y 1.

Eje Y: $TPR = \text{Recall} = TP / (TP + FN)$


Eje X: $FPR = FP / (FP + TN)$

Cada punto: corresponde a un umbral de clasificación diferente.

Curva ROC: muestra el comportamiento del modelo al modificar el umbral.

Línea diagonal: representa un comportamiento equivalente a una clasificación aleatoria.

AUC: resume el área bajo la curva y permite evaluar la capacidad de discriminación.




En el umbral 0.50, la tasa de verdaderos positivos es 98% y la tasa de falsos positivos es 50%; el AUROC 0.85 indica una separación sólida

Métricas de Evaluación – Curva ROC y AUC

Clasificadores de alto desempeño para datos Inmobiliarios con la probabilidad de que una propiedad pertenezca a la categoría (**Premium** o **Standard**)

Curvas ROC Individuales por Modelo Predictivo



Métricas de Evaluación: Regresión

Métricas en Regresión Continua (Pricing / Demanda)

- **RMSE (Raíz del Error Cuadrático Medio):** Penaliza severamente desviaciones grandes y se interpreta en las unidades monetarias del negocio (\$).
- **Coeficiente R^2 (Varianza Explicada):** Expresa el porcentaje de la variabilidad del mercado capturado por el modelo (0% a 100%).
- **Modelo Nulo / Baseline:** Se debe comparar siempre contra la media histórica para demostrar el ROI real del algoritmo frente a la intuición empírica.

Métricas de Evaluación: Regresión

Métrica	Principal aplicación	¿Qué mide?
MAE (Mean Absolute Error)	Regresión	En promedio, cuánto se equivocan las predicciones de un modelo respecto a los valores reales.
RMSE (Root Mean Squared Error)	Regresión	La magnitud promedio del error de las predicciones de un modelo y penaliza los errores grandes.
Covarianza	Análisis estadístico	Cómo varían conjuntamente dos variables

Error Absoluto Medio (MAE)

Cuanto menor sea el MAE, menor es el error promedio del modelo.

$$MAE = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|$$

Donde:

y_i = valor real observado.

$\hat{y}_i$ = valor predicho por el modelo.

n = número de observaciones.

$|y_i - \hat{y}_i|$ = error absoluto de cada predicción.

Root Mean Squared Error (RMSE)

Cuanto menor sea el RMSE, mejor es el desempeño predictivo del modelo.

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2}$$

Donde:

y_i = valor real observado.

$\hat{y}_i$ = valor predicho por el modelo.

n = número de observaciones.

$(y_i - \hat{y}_i)^2$ = error elevado al cuadrado.

Métricas de Evaluación: Regresión

Supongamos un modelo para pronosticar la **demanda de productos**. Un error pequeño puede ser manejable, pero un error muy grande podría generar **quiebres de inventario, sobrecostos o pérdida de ventas**.

En este escenario, el RMSE ayuda a identificar modelos que, aunque tengan un buen desempeño promedio, pueden generar errores de gran magnitud que representan un riesgo para la operación.

Regla práctica:

MAE → “¿Cuánto me equivoco normalmente?”

RMSE → “¿Qué tan importantes son mis errores grandes?”

Métricas de Evaluación: Indicadores Ejecutivos en Clasificación

Exactitud (Accuracy)

- Fórmula: $(TP + TN) / \text{Total}$
- Advertencia de Negocio:
Es sumamente engañosa ante clases desbalanceadas
 - Por ejemplo, fraude al 1%, donde predecir siempre 'no fraude' daría 99% de exactitud ficticia.

Precisión (Precision)

- Fórmula: $TP / (TP + FP)$
- Pregunta relevante: De todas las alarmas generadas, ¿cuántas fueron reales?
- Vital para optimizar recursos operativos y no saturar a los analistas de fraude.

Exhaustividad (Recall)

- Fórmula: $TP / (TP + FN)$
- Pregunta clave: De todos los casos críticos existentes, ¿cuántos logró capturar el algoritmo?
- Prioridad máxima en riesgos de crédito, ciberseguridad y salud.

F1-Score y ROC-AUC


- F1-Score: Media armónica que penaliza desbalances entre Precisión y Recall.
- Curva ROC-AUC: Capacidad global del algoritmo para discriminar entre clases en todos los umbrales de decisión.

Validación cruzada (Cross-Validation)

La validación cruzada es una técnica utilizada para evaluar qué tan bien un modelo de Machine Learning puede generalizar a **datos que no ha visto durante su entrenamiento**.

Qué permite detectar?

1. **Sobreajuste (overfitting)**: el modelo funciona muy bien con los datos de entrenamiento, pero pierde desempeño con datos nuevos.
2. **Variabilidad del modelo**: permite observar si su desempeño cambia significativamente dependiendo de los datos utilizados.
3. **Capacidad de generalización**: proporciona una estimación más robusta del desempeño esperado.



Validación cruzada (Cross-Validation)

Antes de automatizar una decisión de negocio con **Inteligencia Artificial**, se debe demostrar que el modelo aprende del histórico de datos y se puede **generalizar de manera confiable** hacia nuevos datos.

Interpretación de las métricas:


- Accuracy: ¿Cuántos clasificamos correctamente?
- Precision: De los que predijimos como positivos, ¿cuántos realmente lo eran?
- Recall: De los positivos reales, ¿cuántos logramos encontrar?
- F1-Score: ¿Qué tan equilibrados están Precision y Recall?

En transformación digital, la métrica adecuada depende del costo de equivocarse.

- Por ejemplo, si para la empresa es muy importante no dejar escapar clientes que realmente van a abandonar, el **Recall** puede ser especialmente relevante.
- Si, por el contrario, las campañas de retención son costosas y se quiere evitar contactar innecesariamente a clientes que no abandonarían, la **Precision** adquiere mayor importancia.



Modelos de machine Learning no supervisados




Aprendizaje No Supervisado: Reducción Dimensional con PCA

Fundamento y Retorno de Inversión

- **El Reto de la Dimensionalidad:** Operar con decenas de variables correlacionadas eleva los costos de cómputo en la nube e induce **multicolinealidad** (variables que representan lo mismo: peso Kg, peso lb).
- **Proyección Ortogonal:** PCA transforma variables en ejes sintéticos no correlacionados, ordenados por la varianza que retienen.
- **Síntesis en 2D (63.4% Varianza):** Permite proyectar en cuadros de mando ejecutivos la separabilidad natural de casos biológicos o comerciales complejos.
- **Optimización Cloud:** Reduce sustancialmente el ancho de banda y la latencia en arquitecturas de inferencia en tiempo real.

Proyección 2D del Hiperespacio de Variables



Aprendizaje No Supervisado: K-Means - segmentación basada en similitud

K-Means: del resultado a la decisión

- **K-Means** es un algoritmo de clustering no supervisado que agrupa clientes en K

Definir K: número de segmentos que queremos encontrar.

Inicializar centroides: seleccionar **K** puntos iniciales.

Asignar clientes: cada cliente se asigna al centroide más cercano.

Actualizar centroides: se calcula el centro de cada grupo.

Repetir: asignación y actualización hasta que los grupos se estabilicen

Cluster	Ingreso	Gasto	Interpretación
1	Alto	Alto	Clientes de alto valor
2	Alto	Bajo	Potencial de activación
3	Bajo	Alto	Clientes sensibles a promociones
4	Bajo	Bajo	Menor intensidad de compra

Cómo determinamos el número de segmentos?

Utilizar el **método del codo (Elbow Method)**. Se analiza cómo disminuye la variabilidad interna de los grupos a medida que aumenta **K**.

$$WCSS = \sum_{k=1}^K \sum_{x_i \in C_k} ||x_i - \mu_k||^2$$

Donde:

C_k = grupo k .

μ_k = centroide del grupo.

x_i = cliente.

El “**Elbow**” representa un punto donde aumentar el número de clusters genera mejoras cada vez menores.

Aprendizaje No Supervisado: DBSCAN (Density-Based Spatial Clustering of Applications with Noise)

DBSCAN: descubrir grupos por densidad



• DBSCAN pregunta ¿qué clientes se **parecen**?, ¿dónde existen **concentraciones** de comportamiento y qué clientes se **comportan** de manera **atípica**?

Dos parámetros fundamentales

- **ϵ (eps) distancia MAX** para considerar que dos puntos están próximos.
- **MinPts** puntos necesarios para que existe una **región densa**.

Conceptos principales

- **Core point:** suficientes vecinos dentro de ϵ .
- **Border point:** cerca de un punto núcleo y con pocos vecinos.
- **Noise/Outlier:** no esta en una región suficientemente densa.

Característica	K-Means	DBSCAN
Número de clusters	Debe definirse K	No se define previamente
Forma de los clusters	Tiende a grupos compactos	Puede detectar formas diversas
Outliers	Los asigna a algún grupo	Puede identificarlos como ruido
Parámetros	K	ϵ y MinPts
Sensibilidad	Centroides y escala	ϵ , MinPts y escala

DBSCAN podría identificar:

- 👥 Una concentración de clientes con ingresos y gasto similares.
- 👥 Otra concentración con comportamiento diferente.

⚠️ Clientes aislados con **comportamientos poco frecuentes**. Estos últimos pueden ser interesantes para investigar:
¿Son clientes excepcionales, errores en los datos o comportamientos que representan una **oportunidad de negocio**?

Aprendizaje No Supervisado: Agglomerative Hierarchical Clustering

Clustering Jerárquico: construir una estructura de segmentos

- Permite comprender qué **clientes pertenecen al mismo grupo** y cómo se relacionan los diferentes grupos entre sí.
1. Cada cliente comienza como un clúster
 2. Se calcula la distancia entre los clientes/grupos.
 3. Se fusionan los dos grupos más cercanos.
 4. Se recalculan las distancias.
 5. Se repite el proceso hasta obtener un único grupo.

Por ejemplo:

- Personalización de ofertas.
- Campañas específicas por segmento.
- Programas de fidelización.
- Recomendaciones de productos.
- Diferenciación de experiencias digitales.

Aplicación estratégica:
Una organización podría pasar de:

- Datos de clientes
- Patrones de comportamiento
- Segmentos
- Perfiles de clientes
- Estrategias diferenciadas

**Clustering Jerárquico:
del dendrograma a la
estrategia**

**El principal valor es
que permite observar
la jerarquía de
relaciones entre los
clientes.**


Aprendizaje No Supervisado: Paradigmas de Agrupamiento (Clustering)

Tres Enfoques para la Toma de Decisiones en la Organización


- K-Means (Particional): Segmentación por centroides de alta velocidad $O(N)$; ideal para carteras masivas.
- DBSCAN (Densidad): Aísla observaciones periféricas (-1) para detección de fraude, anomalías operacionales y fallas.
- Jerárquico (Ward): Construye taxonomías multinivel para comités directivos mediante dendrogramas.

Contraste Visual de los Tres Algoritmos en el Espacio PCA


K-Means (Centroides)



DBSCAN (Densidad / Outliers)



Jerárquico (Ward)




Métricas de Evaluación: Matriz de Confusión y Costos Asimétricos

Traducción Financiera de los Errores de Predicción

- **Falso Positivo (Error Tipo I):** El modelo genera una alarma errónea. Induce costo de fricción operacional (ej. bloquear a un cliente legítimo en banca digital).
- **Falso Negativo (Error Tipo II):** El modelo no detecta un evento crítico real. Induce pérdida patrimonial o de salud (ej. fraude sistemático o diagnóstico desatendido).
- **La toma de decisión:** En la organización, los modelos no se seleccionan por precisión matemática abstracta, sino calibrando el umbral contra la estructura de pérdidas y ganancias corporativa.

Matriz de Confusión Real (Random Forest)



Métricas de Evaluación: Clustering

Métricas en Agrupamiento No Supervisado

- **Inercia y Método del Codo (elbow method):** Busca el punto de inflexión donde añadir más clusters no compensa la complejidad del portafolio.
- **Coeficiente de Silueta (Silhouette):** Mide cohesión interna vs. separación del cluster vecino más próximo (rango $[-1, 1]$). Valores > 0.40 indican fronteras bien definidas.
- **Dendrograma (Ward):** Permite a la dirección seleccionar la altura de corte según el nivel de granularidad estratégica requerido (Macro vs. Micro-segmentación).

Métricas de Evaluación: Clustering

En clustering normalmente no tenemos una variable objetivo y conocida. Por eso evaluamos aspectos como:

- **Cohesión:** ¿qué tan cercanos están los elementos dentro de un mismo cluster?
- **Separación:** ¿qué tan alejados están los diferentes clusters?

Silhouette Score

Combina cohesión y separación:

$$S = \frac{b - a}{\max(a, b)}$$

Donde:

a = distancia promedio respecto a los elementos de su propio cluster.

b = distancia promedio respecto al cluster vecino más cercano.

Interpretación:


$$-1 \leq S \leq 1$$

Cercano a 1 → clusters bien separados.

Cercano a 0 → clusters superpuestos.

Menor que 0 → posibles asignaciones incorrectas.

Método Elbow (Clusters K)



Métricas de Evaluación: Dengrograma


- Es un diagrama en forma de árbol que permite visualizar cómo se van agrupando los datos según su similitud o distancia. Es especialmente utilizado en el clustering jerárquico.
- El dendrograma muestra la historia de cómo los datos se van agrupando; la altura indica qué tan diferentes son los grupos que se están uniendo.

Permite observar cómo se formaron los grupos, no solamente el resultado final.

Para la segmentación de los clientes:

- Las hojas representan las **observaciones**.
- Las ramas muestran **qué elementos se van agrupando**.
- La altura a la que se unen dos grupos representa su **distancia o disimilitud**.
- Uniones a baja altura → **elementos similares**.
- Uniones a mayor altura → **elementos diferentes**.

Dendrograma



Gobernanza, Validación y Prevención del Riesgo Analítico

1. Partición Inesgada (Holdout Split)

- Principio: Separar rígidamente los datos de entrenamiento (80%) y prueba final (20%).
- Valor Directivo: Garantiza que la efectividad del modelo reportada a la junta no sea producto de sobreajuste o memorización de datos.

2. Validación Cruzada (K-Fold CV)

- Principio: Dividir los datos de entrenamiento en K pliegues iterativos.
- Valor Directivo: Estima con certeza la estabilidad y dispersión del modelo (media $\pm$ desviación) ante cambios en el entorno operativo.

3. Control de Fuga (Data Leakage)

- Principio: Calibrar escaladores y selectores de variables exclusivamente sobre Train.
- Valor Directivo: Previene falsos éxitos en desarrollo que fracasan estrepitosamente al desplegarse en sistemas transaccionales reales.

Gestión estratégica

1. Priorización por ROI

Traducir cuellos de botella del negocio a soluciones analíticas:

- Churn / Retención → Reg. Logística / XGBoost
- Pricing Dinámico → Regresión Múltiple / RF
- Segmentación y CLV → K-Means / Jerárquico
- Detección de Fraude → DBSCAN / Ensamblés

2. Eficiencia Cloud

Liderar comités de arquitectura analítica implementando:

- Reducción con PCA y selección con RFE para comprimir el gasto en cómputo cloud.
- Aceleración de los tiempos de inferencia en canales digitales transaccionales.

3. Decisión por Costos

Configurar matrices de confusión y umbrales operativos no por precisión matemática abstracta, sino ponderando el impacto financiero de los falsos positivos y falsos negativos en la cuenta de resultados.

4. Liderazgo Ético y XAI

Fomentar una cultura corporativa guiada por datos (Data-Driven), asegurando algoritmos auditables, explicables ante comités directivos y en estricto cumplimiento normativo y ético.

bibliografía

- Olumide, Shittu (2026). Machine Learning Trends to Watch in 2026. Practical Machine Learning. <https://machinelearningmastery.com/7-machine-learning-trends-to-watch-in-2026/>.
- Geertsema, Paul (2023). Machine Learning for Managers. First published by Routledge. Taylor & Francis Group, an informa business.
- Hwang, Y. y Burtch, N. (2024). *Machine Learning and Generative AI for Marketing*. Packt Publishing. ISBN 978-1-83588-940-4.
- Ping, D. (2024). The Machine Learning Solutions Architect Handbook. Packt Publishing. ISBN 978-1-80512-250-0.
- Reddi, J. (2025). Machine Learning Systems. School of Engineering and Applied Sciences Harvard University.
- Fuentes, A. (2018). Become a Python Data Analyst. Packt Publishing. ISBN 978-1-78728-430-2.
- Santamaría-Granados, L (2019). Using Deep Convolutional Neural Network for Emotion Detection on a Physiological Signals Dataset (AMIGOS). <https://ieeexplore.ieee.org/document/8543567>
- https://scikit-learn.org/stable/modules/cross_validation.html